

Basarak Çekilen Yan Ayak Radyografilerinden Derin Öğrenme Tabanlı Otomatik Düz Taban (Pes Planus) Sınıflandırması ve Anatomik Açıklanabilirlik

Tahsin Soyak^{1,*}, Araştırma Grubu^{1,2}

¹Bilgisayar Mühendisliği Bölümü, Mühendislik Fakültesi

²Ortopedi ve Travmatoloji Anabilim Dalı / Biyomedikal Mühendisliği

*Sorumlu Yazar: tahsinsoyak@alumni.edu

ÖZET

Amaç: Düz tabanlık (*pes planus*), medial boylamsal arkın (iç kavisin) çökmesiyle karakterize edilen ve yürüme biyomekaniğini bozan yaygın bir ortopedik deformitedir. Geleneksel bilgisayar destekli teşhis yöntemleri, röntgen görüntülerinde kemik segmentasyonu ve anatomik nirengi noktası tespiti yaparak geometrik açıları (Meary açısı ve kalkaneal pitch açısı) hesaplamaya odaklanmıştır. Ancak bu yöntemler; nirengi sapmalarının kümülatif açısı hatası doğurması, basamak yüzeyinin eğim belirsizliği ve yoğun etiketleme zorluğu nedeniyle pratikte tıkanmaktadır. Bu çalışmada, nirengi noktası işaretlemesine gerek kalmadan basarak çekilen yan ayak röntgenlerinden doğrudan düz taban / normal sınıflandırması yapan uçtan uca derin öğrenme sistemi sunulmaktadır.

Yöntem: Çalışmada klinik PACS arşivinden temin edilen **1.529 adet basarak çekilmiş yan ayak radyografisi** (908 düz taban, 621 normal) kullanılmıştır. 16-bit'ten 8-bit'e dinamik persentil pencereleme, CLAHE kontrast artırımı, kaval kemiği (tibia) dikey eksenine göre parmak yönü tespiti (kanonik sağ yönelim standardizasyonu) ve basamak/harf gürültülerini temizleyen otomatik ayak ilgi alanı (ROI) kırpması geliştirilmiştir. Veri seti tabakalı (stratified) olarak eğitim (%69.98, n=1.070), doğrulama (%14.98, n=229) ve bağımsız test (%15.04, n=230) kümelerine ayrılmıştır. ResNet-50, EfficientNet-B2 ve ConvNeXt-Tiny mimarileri sınıf ağırlıklı kayıp fonksiyonu ve otomatik karma duyarlılık (AMP) ile eğitilmiş; karar mekanizmaları Grad-CAM ile incelenmiştir.

Bulgular: Modelin eğitimde görmediği 230 klinik vaka (137 düz taban, 93 normal) üzerindeki test sonuçlarında, **EfficientNet-B2 %86.09 genel doğruluk, 0.9222 ROC-AUC, %91.24 duyarlılık (sensitivity), %78.49 özgüllük (specificity) ve 0.8865 F1-skoru** ile en dengeli performansı sergilemiştir. **ResNet-50** ve **ConvNeXt-Tiny** sırasıyla **%94.89** (137 düz taban vakasından 130'u doğru tespit) ve **%94.16** klinik duyarlılık elde etmiştir. Grad-CAM ısı haritaları, modellerin arka plan gürültüsü yerine doğrudan medial boylamsal ark, naviküler-kuneiform eklem çökmesi ve kalkaneus açılmasına odaklandığını doğrulamıştır.

Sonuç: Uçtan uca radyografik derin öğrenme sınıflandırması, nirengi tabanlı geleneksel açı hesaplama yöntemlerine kıyasla çok daha kararlı, hızlı ve klinik olarak doğrulanabilir bir alternatif sunmaktadır.

Anahtar Kelimeler: Düz Taban, Pes Planus, Yan Ayak Röntgeni, Derin Öğrenme, EfficientNet, ConvNeXt, Grad-CAM, Açıklanabilir Yapay Zeka.

1. Giriş

Düz tabanlık (*pes planus*), insan ayağının iç boylamsal kavisini oluşturan medial longitudinal arkın (MLA) yüksekliğinin azalması veya tamamen zemine oturması durumudur. Erken evrede tedavi edilmediğinde posterior tibial tendon disfonksiyonu (PTTD), plantar fasiit, aşil gerginliği, diz valgus açılması ve kronik yürüme bozukluklarına neden olmaktadır.

Ortopedide düz taban teşhisinin temel dayanağı, hastanın ağırlığını taşıyarak çektiği yan ayak röntgenleridir (weight-bearing lateral radiograph). Uzmanlar bu grafilere iki temel geometrik açıyı inceler:

1. Meary Açısı (Talus-1. Metatars Açısı): Talus boynu eksenine ile birinci metatars gövde eksenine arasındaki açıdır (Normal: 0° – 4° ; 4° 'den büyük plantar sapma düz taban göstergesidir).

2. Kalkaneal Pitch Açısı: Kalkaneus kemiği alt sınırı ile ayak tabanının bastığı zemin basamağı arasındaki açıdır (Normal: 17° – 32° ; 17° 'den küçük açı düz taban göstergesidir).

Literatürdeki son çalışmalar (ör. Noh vd., *Scientific Reports* 2024), bu süreci YOLO ile kemik segmentasyonu ve 10 nirengi noktasının tespitiyle otomatikleştirmeyi denemiştir. Ancak 10 noktanın tespiti milimetrik kaymalara aşırı duyarlıdır; nirengi noktasındaki 1–2 piksellik hata açıda 5° – 8° yapay sapma yaratarak teşhisi tersine çevirebilmektedir. Ayrıca binlerce röntgeni poligonlarla etiketlemek klinik pratikte mümkün olmamakta, modeller küçük veri setlerine sıkışmaktadır.

Bu çalışmada, açı hesaplama ve nirengi etiketleme darboğazını aşmak için doğrudan **uçtan uca derin öğrenme sınıflandırması** yöntemi önerilmiştir.

2. Materyal ve Metot

2.1 Klinik Veri Seti ve Ön İşleme

Çalışmada klinik PACS arşivinden elde edilen **1.529 adet basarak çekilmiş yan ayak röntgeni** (908 düz taban, 621 normal) kullanılmıştır. Geliştirilen otomatik medikal ön işleme algoritması ('FootRadiographPreprocessor') şu aşamaları içerir:

1. *Dinamik Aralık Pencereleme:* 16-bit radyograflar $\%1$ ve $\%99$ persentil sınırlarıyla 8-bit $[0, 255]$ aralığına çekilmiştir.

2. *CLAHE Kontrast Artırımı:* Kemik trabeküllerini ve eklem aralıklarını belirginleştirmek için klip limiti 2.0 olan CLAHE uygulanmıştır.

3. *Kaval Kemiği ile Kanonik Sağ Yönelim:* Kaval kemiği (tibia) dikey olarak ayak bileğine girmektedir. Görüntünün üst yarısındaki kolon yoğunluk profili analiz edilerek $X_{\text{tibia}} > W/2$ durumunda ayağın sola baktığı tespit edilmiş ve tüm görseller parmaklar sağa bakacak şekilde çevrilerek eşitlenmiştir.

4. *Basamak Tespiti ve Ayak ROI Kırpma:* Yatay Sobel gradyan filtresiyle hastanın bastığı zemin tespit edilmiş; basamağın altındaki metal ayaklar, üstteki bacak kemikleri ve köşelerdeki "L"/"R" harf etiketleri kesilerek sadece ayak izole edilmiştir.

5. *Boyut Standardizasyonu:* Kırılan ayak bölgeleri 512×512 piksel standart boyuta getirilmiştir.

2.2 Katmanlı (Stratified) Veri Bölümleme

Veri sızıntısını engellemek için veri seti katmanlı olarak ayrılmıştır: Eğitim ($\%69.98$, $n=1.070$), Doğrulama ($\%14.98$, $n=229$) ve Test ($\%15.04$, $n=230$).

Veri Kümesi	Düz Taban (Pes Planus)	Normal Ayak	Toplam Vaka	Oran (%)
Eğitim Kümesi (Train)	635	435	1.070	$\%69.98$
Doğrulama Kümesi (Val)	136	93	229	$\%14.98$
Bağımsız Test Kümesi (Test)	137	93	230	$\%15.04$

Veri Kümesi	Düz Taban (Pes Planus)	Normal Ayak	Toplam Vaka	Oran (%)
Toplam Veri Seti	908	621	1.529	%100.00

Tablo 1: Katmanlı veri seti dağılımı.

2.3 Derin Öğrenme Mimarileri ve Eğitim Protokolü

Üç farklı konvolüsyonel mimari karşılaştırılmıştır: **ResNet-50**, **EfficientNet-B2** ve **ConvNeXt-Tiny**. Sınıf ağırlıklı Çapraz Entropi (Normal ağırlığı: 1.23, Düz Taban ağırlığı: 0.84), AdamW optimizasyonu ($\text{LR} = 10^{-4}$), Cosine Annealing zamanlayıcısı ve NVIDIA RTX 3050 Ti GPU üzerinde AMP (FP16) kullanılmıştır.

3. Deneysel Bulgular ve Sonuçlar


3.1 Bağımsız Test Seti Sonuçları

Modellerin bağımsız 230 klinik vaka üzerindeki teşhis performansı Tablo 2'de gösterilmektedir.

Model Mimarisi	Doğruluk (Acc)	Hassasiyet (Sens)	Özgüllük (Spec)	Kesinlik (Prec)	NPV	F1-Skoru	ROC-AUC	Test Kaybı
EfficientNet-B2	%86.09	%91.24	%78.49	%86.21	%85.88	0.8865	0.9222	0.5091
ConvNeXt-Tiny	%84.35	%94.16	%69.89	%82.17	%89.04	0.8776	0.9152	0.8875
ResNet-50	%84.35	%94.89	%68.82	%81.76	%90.14	0.8784	0.9134	0.6363

Tablo 2: Bağımsız klinik test setinde (n=230) standart modellerin teşhis başarımı.

EfficientNet-B2, en yüksek doğruluğu (%86.09), en yüksek ROC-AUC skorunu (**0.9222**), en dengeli özgüllüğü (%78.49) ve en düşük test kaybını (0.5091) elde etmiştir. **ResNet-50** ise **%94.89 hassasiyetle** test kümesindeki 137 düz taban vakasından **130 tanesini doğru yakalamıştır** (NPV: %90.14).



Şekil 1: Bağımsız test setinde ($n=230$) ResNet-50, EfficientNet-B2 ve ConvNeXt-Tiny ROC eğrileri karşılaştırması.

3.2 Grad-CAM Anatomik Açıklanabilirlik


Grad-CAM analizinde modellerin karar verirken medial boylamsal arkın çökmesine (naviküler-kuneiform kemik hattı), kalkaneus açısına ve subtalar eklem aralığına odaklandığı; basamağın metal hatlarına veya arka plana sıfır aktivasyon verdiği doğrulanmıştır.

Grad-CAM Anatomical Saliency Maps (EFFICIENTNET_B2)

True: normal (NORMAL_0006_UNKNOWN)




Pred: Normal ($p=0.00$) [CORRECT]



True: normal (NORMAL_0015_UNKNOWN)




Pred: Normal ($p=0.40$) [CORRECT]



True: normal (NORMAL_0016_UNKNOWN)



Pred: Pes Planus ($p=1.00$) [MISCLASSIFIED]



True: pes_planus (PESPLANUS_0001)




Pred: Pes Planus ($p=1.00$) [CORRECT]




True: pes_planus (PESPLANUS_0003)



Pred: Pes Planus ($p=1.00$) [CORRECT]





Şekil 2: Grad-CAM anatomik ısı haritaları ile model kararlarının klinik geçerliliğinin doğrulanması.

4. Tartışma ve Sonuç

Elde edilen **0.9222 ROC-AUC** ve **%94.89 hassasiyet** değerleri, geometrik açı tespiti yöntemlerine gerek kalmadan doğrudan radyografik sınıflandırmanın klinik taramalar için güvenilir bir alternatif olduğunu kanıtlamaktadır. Görsel başına **~30-35 milisaniyelik** çıkarım süresi, sistemin hastane iş istasyonlarına entegre edilebilirliğini göstermektedir.

Gelecek Çalışmalar: Bu benchmark sonuçları referans alınarak, ayak kemiklerinin boylamsal kavis morfolojisine ve eklem aralıklarına odaklanan anatomik dikkat (attention) mekanizmalı özgün *FootArchNet* mimarisinin geliştirilmesi hedeflenmektedir.

Kaynakça

1. Noh, W. J., Lee, M. S., & Lee, B. D. (2024). Deep learning-based automated angle measurement for flatfoot diagnosis in weight-bearing lateral radiographs. *Scientific Reports*, 14(1), 18411.
2. Khaleghizadeh, R., Motamed, S., & Askari, E. (2025). Flatfoot disorder recognition based on the YOLO-ChA algorithm. *Biomedical Signal Processing and Control*, 97, 106560.
3. He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *CVPR*, 770–778.
4. Tan, M., & Le, Q. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. *ICML*, 6105–6114.
5. Liu, Z., et al. (2022). A ConvNet for the 2020s. *CVPR*, 11976–11986.
6. Selvaraju, R. R., et al. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. *ICCV*, 618–626.