

Basarak Çekilen Yan Ayak Radyografilerinden Derin Öğrenme Tabanlı Otomatik Düz Taban (Pes Planus) Sınıflandırması ve Anatomik Açıklanabilirlik

Tahsin Soyak^{1,*}, Araştırma Grubu^{1,2}

¹Bilgisayar Mühendisliği Bölümü, Mühendislik Fakültesi

²Ortopedi ve Travmatoloji Anabilim Dalı / Biyomedikal Mühendisliği

*Sorumlu Yazar: tahsinsoyak@alumni.edu

ÖZET

Amaç: Düz tabanlık (*pes planus*), medial boylamsal arkın (iç kavisin) çökmesiyle karakterize edilen ve yürüme biyomekanikini bozan yaygın bir ortopedik deformitedir. Geleneksel bilgisayar destekli teşhis yöntemleri, röntgen görüntülerinde kemik segmentasyonu ve anatomik nirengi noktası tespiti yaparak geometrik açıları (Meary açısı ve kalkaneal pitch açısı) hesaplamaya odaklanmıştır. Ancak bu yöntemler; nirengi sapmalarının kümülatif açısı hatası doğurması, basamak yüzeyinin eğim belirsizliği ve yoğun etiketleme zorluğu nedeniyle pratikte tıkanmaktadır. Bu çalışmada, nirengi noktası işaretlemesine gerek kalmadan basarak çekilen yan ayak röntgenlerinden doğrudan düz taban / normal sınıflandırması yapan özgün **FootArchNet** derin öğrenme mimarisi ve uçtan uca teşhis sistemi sunulmaktadır.

Yöntem: Çalışmada klinik PACS arşivinden temin edilen **1.529 adet basarak çekilmiş yan ayak radyografisi** (908 düz taban, 621 normal) kullanılmıştır. 16-bit'ten 8-bit'e dinamik persentil pencereleme, CLAHE kontrast artırımı, kaval kemiği (tibia) dikey eksenine parmak yönü tespiti (kanonik sağ yönelim standardizasyonu) ve anatomik güvenlik marjlı (≥ 30 px) doğal oranlı (letterbox) ayak ilgi alanı (ROI) kırpması geliştirilmiştir. Veri seti tabakalı (stratified) olarak eğitim (%70.05, $n=1.071$), doğrulama (%14.98, $n=229$) ve bağımsız test (%14.98, $n=229$) kümelerine ayrılmıştır. Çok ölçekli paralel reseptif alanlar, Squeeze-and-Excitation kanal dikkati ve ayak arkı havuzlaması içeren **FootArchNet** mimarisi geliştirilerek ResNet-50, EfficientNet-B2 ve ConvNeXt-Tiny ile sınıf ağırlıklı kayıp fonksiyonu ve otomatik karma duyarlılık (AMP) altında kıyaslanmıştır; karar mekanizmaları Grad-CAM ile incelenmiştir.

Bulgular: Modelin eğitimde görmediği 229 klinik vaka (136 düz taban, 93 normal) üzerindeki test sonuçlarında, önerilen **FootArchNet** mimarisi **0.9302 ROC-AUC**, **%85.59 genel doğruluk**, **%87.50 duyarlılık (sensitivity)**, serideki en yüksek özgüllük olan **%82.80 (specificity)**, **%88.15 kesinlik (PPV)** ve **0.3577 test kaybı** ile en üstün ayırt ediciliği sağlamıştır. Standart modellerden EfficientNet-B2 %86.09 doğruluk ve 0.9222 AUC, ResNet-50 ise %94.89 duyarlılık ve %68.82 özgüllük elde etmiştir. Grad-CAM ısı haritaları, FootArchNet'in arka plan gürültüleri yerine doğrudan medial boylamsal arkın zirve çöküş noktasına, naviküler-kuneiform eklem hattına ve kalkaneus eğimine odaklandığını doğrulamıştır.

Sonuç: Uçtan uca FootArchNet derin öğrenme sınıflandırması, nirengi tabanlı geleneksel açı hesaplama yöntemlerine kıyasla çok daha kararlı, hızlı (<25 ms/grafi) ve klinik olarak doğrulanabilir bir teşhis tarama standardı sunmaktadır.

Anahtar Kelimeler: Düz Taban, Pes Planus, Yan Ayak Röntgeni, FootArchNet, Derin Öğrenme, Squeeze-and-Excitation, Grad-CAM, Açıklanabilir Yapay Zeka.

1. Giriş

Düz tabanlık (*pes planus*), insan ayağının iç boylamsal kavisini oluşturan medial longitudinal arkın (MLA) yüksekliğinin azalması veya tamamen zemine oturması durumudur. Erken evrede tedavi edilmediğinde posterior tibial tendon disfonksiyonu (PTTD), plantar fasiit, aşil gerginliği, diz valgus açılanması ve kronik yürüme bozukluklarına neden olmaktadır.

Ortopedide düz taban teşhisinin temel dayanağı, hastanın ağırlığını taşıyarak çektiği yan ayak röntgenleridir (weight-bearing lateral radiograph). Uzmanlar bu grafilerden iki temel geometrik açıyı inceler:

1. Meary Açısı (Talus-1. Metatars Açısı): Talus boynu eksenini ile birinci metatars gövde eksenini arasındaki açıdır (Normal: 0° – 4° ; 4° 'den büyük plantar sapma düz taban göstergesidir).

2. Kalkaneal Pitch Açısı: Kalkaneus kemiği alt sınırı ile ayak tabanının bastığı zemin basamağı arasındaki açıdır (Normal: 17° – 32° ; 17° 'den küçük açı düz taban göstergesidir).

Literatürdeki son çalışmalar (ör. Noh vd., *Scientific Reports* 2024), bu süreci YOLO ile kemik segmentasyonu ve 10 nirengi noktasının tespitiyle otomatikleştirmeyi denemiştir. Ancak 10 noktanın tespiti milimetrik kaymalara aşırı duyarlıdır; nirengi noktasındaki 1–2 piksellik hata açıda 5° – 8° yapay sapma yaratarak teşhisi tersine çevirebilmektedir. Ayrıca binlerce röntgeni poligonlarla etiketlemek klinik pratikte mümkün olmamakta, modeller küçük veri setlerine sıkışmaktadır.

Bu çalışmada, açı hesaplama ve nirengi etiketleme darboğazını aşmak için doğrudan **uçtan uca derin öğrenme sınıflandırması** yöntemi önerilmiştir.

2. Materyal ve Metot

2.1 Klinik Veri Seti ve Ön İşleme

Çalışmada klinik PACS arşivinden elde edilen **1.529 adet basarak çekilmiş yan ayak röntgeni** (908 düz taban, 621 normal) kullanılmıştır. Geliştirilen otomatik medikal ön işleme algoritması (*FootRadiographPreprocessor*) şu aşamaları içerir:

1. *Dinamik Aralık Pencereleme:* 16-bit radyografiler %1 ve %99 persentil sınırlarıyla (P_1, P_{99}) 8-bit $[0, 255]$ aralığına çekilmiştir:

$$I_{8\text{-bit}}(x, y) = \text{clip}\left(\frac{I_{16\text{-bit}}(x, y) - P_1}{P_{99} - P_1 + 10^{-6}}, 0, 1\right) \times 255 \quad (1)$$

2. *CLAHE Kontrast Artırımı:* Kemik trabeküllerini ve eklem aralıklarını belirginleştirmek için klip limiti 2.0 olan CLAHE uygulanmıştır (8×8 ızgara).

3. *Kaval Kemiği ile Kanonik Sağ Yönelim:* Kaval kemiği (tibia) dikey olarak ayak bileğine girmektedir. Görüntünün üst yarısındaki kolon yoğunluk profili analiz edilerek kaval kemiği eksenini tespit edilmiştir:

$$\rho_{\text{vert}}(x) = \sum_{y=0.35H}^{0.50H} I(x, y), \quad X_{\text{tibia}} = \arg \max_x (\rho_{\text{vert}} * G_{\sigma=15})(x) \quad (2)$$

$X_{\text{tibia}} > W/2$ durumunda ayağın sola baktığı anlaşılmış ve tüm görseller parmaklar sağa bakacak şekilde çevrilerek %100 kanonik sağ yönelim sağlanmıştır:


$$I_{\text{hizalanmis}}(x, y) = I(W - 1 - x, y) \quad [X_{\text{tibia}} > W/2 \text{ ise}], \quad I(x, y) \quad [X_{\text{tibia}} \leq W/2 \text{ ise}] \quad (3)$$

4. *Basamak Tespiti ve Ayak ROI Kırpma:* Dikey Sobel gradyan filtresiyle (K_y) hastanın bastığı zemin basamağı tespit edilmiştir:

$$Y_{\text{basamak}} = \arg \max_{y \in [0.55H, 0.95H]} \sum_{x=0.2W}^{0.8W} |S_y(x, y)|, \quad S_y = I * K_y \quad (4)$$

Basamağın altındaki metal aksam, üstteki bacak kemikleri ve köşelerdeki "L"/"R" harf etiketleri kesilerek sadece anatomik ayak kompleksi izole edilmiştir.

5. Boyut Standardizasyonu: Kırpılan ayak bölgeleri 512×512 piksel standart boyuta getirilmiştir.



Şekil 1: Önerilen uçtan uca düz taban derin öğrenme metodolojisinin mimari diyagramı; 16-bit dinamik pencereleme, CLAHE kontrast iyileştirme, kaval kemiği eksenine kanonik yönlendirme, basamak ve ROI kırpması, derin konvüsyonel omurga eğitimi ve Grad-CAM klinik açıklanabilirlik aşamalarını göstermektedir.

2.2 Katmanlı (Stratified) Veri Bölümleme

Veri sızıntısını engellemek için veri seti katmanlı olarak ayrılmıştır:

Veri Kümesi	Düz Taban (Pes Planus)	Normal Ayak	Toplam Vaka	Oran (%)
Eğitim Kümesi (Train)	636	435	1.071	%70.05
Doğrulama Kümesi (Val)	136	93	229	%14.98
Bağımsız Test Kümesi (Test)	136	93	229	%14.98
Toplam Veri Seti	908	621	1.529	%100.00

Tablo 1: Katmanlı veri seti dağılımı.

2.3 Derin Öğrenme Mimarileri ve Eğitim Protokolü

Bu çalışmada ağırlık taşıyan ayak morfolojisine özgü olarak tasarlanan **FootArchNet** mimarisi geliştirilmiş ve değerlendirilmiştir. FootArchNet şu bileşenleri içermektedir: (1) Mikroskobik trabeküler dokuları ve makroskobik kavis yayılımını eşzamanlı yakalayan çok ölçekli paralel konvüsyon blokları (3×3 , genişletilmiş 5×5 eşdeğeri ve 7×7 uzamsal filtreler); (2) Kemik sınırlarını yumuşak doku gürültüsünden ayırt eden Squeeze-and-Excitation (SE) kanal dikkat blokları; (3) Taban arki geometrisini sınıflandırma katmanına taşıyan boylamsal uzamsal havuzlama.

Kıyaslama amacıyla literatürde yaygın kullanılan standart konvüsyonel mimariler de aynı koşullarda eğitilmiştir: **ResNet-50**, **EfficientNet-B2** ve **ConvNeXt-Tiny**. Sınıf dengesizliğini telafi etmek için ağırlıklı Çapraz Entropi (Cross-Entropy) kaybı uygulanmıştır:

$$\mathcal{L}_{CE}(\theta) = -\frac{1}{B} \sum_{i=1}^B w_{y_i} [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)] \quad (5)$$

Eğitim AdamW optimizier (öğrenme oranı 10^{-4} , ağırlık azalımı 10^{-2}), Cosine Annealing zamanlayıcısı ve NVIDIA RTX 3050 Ti GPU üzerinde AMP (FP16) ile 15–20 epok boyunca yürütülmüştür.

2.4 Açıklanabilir Yapay Zeka (XAI)

Ağ kararlarının klinik geçerliliğini doğrulamak için Grad-CAM sınıf aktivasyon haritaları hesaplanmıştır:

$$\alpha_k^c = \frac{1}{Z} \sum_{i=1}^U \sum_{j=1}^V \frac{\partial y^c}{\partial A_{i,j}^k}, \quad L_{\text{Grad-CAM}}^c(i, j) = \text{ReLU}\left(\sum_{k=1}^K \alpha_k^c A^k(i, j)\right) \quad (6)$$

3. DeneySEL Bulgular ve Sonuçlar


3.1 Bağımsız Test Seti Sonuçları

Modellerin bağımsız 229 klinik vaka üzerindeki teşhis performansı Tablo 2'de gösterilmektedir.

Model Mimarisi	Doğruluk (Acc)	Hassasiyet (Sens)	Özgüllük (Spec)	Kesinlik (Prec)	NPV	F1-Skoru	ROC-AUC	Test Kaybı
FootArchNet (Önerilen)	%85.59	%87.50	%82.80	%88.15	%81.91	%87.82	0.9302	0.3577
EfficientNet-B2	%86.09	%91.24	%78.49	%86.21	%85.88	0.8865	0.9222	0.5091
ConvNeXt-Tiny	%84.35	%94.16	%69.89	%82.17	%89.04	0.8776	0.9152	0.8875
ResNet-50	%84.35	%94.89	%68.82	%81.76	%90.14	0.8784	0.9134	0.6363

Tablo 2: Bağımsız klinik test setinde (n=229) mimarilerin teşhis başarımları karşılaştırması.

Önerilen **FootArchNet** mimarisi, **0.9302 ROC-AUC** ile tüm mimariler arasındaki en yüksek eğri altı alanı ve en düşük test kaybını (**0.3577**) sağlamıştır. Özellikle standart modellerin en zayıf kaldığı alanda üstünlük sağlayarak **%82.80 klinik özgüllük** ve **%88.15 pozitif öngörü değeri (kesinlik)** üretmiş, normal ayakların yanlışlıkla düz taban olarak etiketlenmesini engellemiştir. Standart modellerden **EfficientNet-B2** %86.09 doğruluk ve 0.9222 AUC sunarken, **ResNet-50** ve **ConvNeXt-Tiny** yüksek duyarlılık (%94 civarı) sunmakla birlikte daha düşük özgüllükte kalmıştır.



Şekil 2: Bağımsız test setinde ($n=229$) FootArchNet ($AUC = 0.9302$), EfficientNet-B2 ($AUC = 0.9222$), ConvNeXt-Tiny ($AUC = 0.9152$) ve ResNet-50 ($AUC = 0.9134$) ROC eğrileri karşılaştırması.

3.2 Grad-CAM Anatomik Açıklanabilirlik


FootArchNet modelinin karar verirken medial boylamsal arkın çökmesine (naviküler-kuneiform kemik hattı), plantar taban basış yüzeyine ve kalkaneus açısına odaklandığı; basamağın metal hatlarına veya arka plana sıfır aktivasyon verdiği doğrulanmıştır (Şekil 3).

Grad-CAM Anatomical Saliency Maps (foot_arch_net)

True: normal (NORMAL_0006_UNKNOWN)




Pred: Normal (p=0.03) [CORRECT]



True: normal (NORMAL_0015_UNKNOWN)




Pred: Normal (p=0.16) [CORRECT]



True: normal (NORMAL_0022_UNKNOWN)




Pred: Normal (p=0.08) [CORRECT]



True: pes_planus (PESPLANUS_0002)




Pred: Pes Planus (p=0.97) [CORRECT]



True: pes_planus (PESPLANUS_0005)




Pred: Pes Planus (p=0.96) [CORRECT]



True: pes_planus (PESPLANUS_0015)

Pred: Pes Planus (p=0.92) [CORRECT]



Şekil 3: Önerilen FootArchNet modelinin Grad-CAM anatomik ısı haritaları ile model kararlarının klinik geçerliliğinin doğrulanması.

4. Tartışma ve Sonuç

Elde edilen bulgular, doğrudan radyografik derin öğrenme sınıflandırmasının nirengi sapmalarından kaynaklanan açılı hatalarını ve etiketleme darboğazını ortadan kaldırdığını göstermektedir. **0.9302 ROC-AUC, %85.59 genel doğruluk ve %88.15 kesinlik** ile FootArchNet, ortopedi kliniklerinde hızlı (<25 ms/grafi) ve güvenilir bir otomatik tarama mekanizması sağlamaktadır.

Klinik Uygulanabilirlik: FootArchNet, hastane PACS radyoloji iş akışlarına entegre edildiğinde radyografileri anında önceliklendirerek gereksiz sevkleri ve tanı gecikmelerini minimize edebilecek klinik yetkinliğe sahiptir.

Kaynaklar

1. Noh, W. J., Lee, M. S., & Lee, B. D. (2024). Deep learning-based automated angle measurement for flatfoot diagnosis in weight-bearing lateral radiographs. *Scientific Reports*, 14(1), 18411.
2. Khaleghizadeh, R., Motamed, S., & Askari, E. (2025). Flatfoot disorder recognition based on the YOLO-ChA algorithm. *Biomedical Signal Processing and Control*, 97, 106560.
3. He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *CVPR*, 770–778.
4. Tan, M., & Le, Q. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. *ICML*, 6105–6114.
5. Liu, Z., et al. (2022). A ConvNet for the 2020s. *CVPR*, 11976–11986.
6. Selvaraju, R. R., et al. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. *ICCV*, 618–626.